

混合检索与重排序技术白皮书

双路召回：向量与全文各有所长


向量检索把文本映射到高维语义空间，擅长捕捉意思相近但用词不同的相关性，例如多少钱和价格是多少在语义上很接近；全文检索基于关键词匹配和词频统计，擅长专有名词、型号、编号这类必须精确命中的场景。单独依赖任何一路都会有明显短板，因此生产级检索系统通常同时跑向量与全文两路召回，再把结果融合，取长补短。

融合与重排序

两路候选集的原始分数纲完全不同：余弦相似度落在有界区间，而全文检索的原始分数没有上界，直接相加会让全文分数淹没向量分数。常见做法是先对每路候选集做归一化，再按权重加权，或者使用倒数排名融合，不依赖具体分值，只看排名先后，天然免疫量纲问题。融合之后的候选集通常还会经过一个专门的重排模型二次打分，重排模型能同时看到问题和候选片段的完整语义交互，排序质量明显优于任何单一召回路径，但计算成本更高，因此只对经过初筛的候选集起作用，并设置合理的超时与降级策略，避免拖慢整体响应。

阈值与父子分片的返回粒度

业务上还需要一个宁缺毋滥的开关：把最终得分低于阈值的结果过滤掉，避免返回明显不相关的内容。如果知识库启用了父子分片，检索用小片，展示回大片，阈值与最终返回条数就要作用在合并后的父片维度上，而不是子片维度，这样用户看到的答案上下文才是连贯完整的，不会出现同一段父片内容被多次重复计数的情况。下图展示了从原始文档到最终生成答案的完整链路。



图：文档从上传到生成答案的索引与检索流水线（自绘示意图，用于验证 VLM 图片理解链路）